Цифровой хаос в Дашборге

Elena Ubogoeva

Задача:

Вечером 25 марта 2025 года система доставки пиццы в Дашборге дала сбой: заказы пропали, курьеры остались без маршрутов, а клиенты — без ужина. Это не случайность, а преднамеренное вмешательство.

Давайте выясним, что случилось, восстановим данные, найдем предполагаемого злоумышленника и распределим компенсацию 90000 рублей пострадавшим пользователям.

Восстановление данных

Частично восстановленные данные есть по ссылке, таблицы `orders` и `device`.

Начнем с загрузки данных и посмотрим на структуру данных.

```
head(orders)
```

```
   order_id                order order_price user_id
      <num>               <char>       <num>   <num>
1:      999 Мясной микс, 3 пиццы        1878  102475
2:      680          Мясной микс         579  218841
3:      687          Мясной микс         579  521065
4:      685               Дьябло         560  106146
5:      683          Сицилийская         545  854950
6:      678                 <NA>         530  263835
```

```
head(device)
```

```
                ip  device     operator_ip user_id
            <char>  <char>          <char>   <num>
1:  192.168.66.187 unknown 192.168.215.115  102475
2: 192.168.100.221  mobile 192.168.203.103  218841
3: 192.168.100.221  mobile 192.168.202.102  521065
4: 192.168.100.221     web 192.168.212.112  106146
5: 192.168.100.221  mobile 192.168.217.117  854950
6: 192.168.100.221     web 192.168.209.109  263835
```

Подсчитаем, сколько значений было пропущено и в каких столбцах

```
colSums(is.na(orders))
```

```
   order_id       order order_price     user_id
          0         269           0           0
```

```
colSums(is.na(device))
```

```
         ip      device operator_ip     user_id
          0           0           0           0
```

У нас есть пропущенные значения в составе заказа (поле order), нужно их восстановить. Мы можем восстановить цену отдельных пицц, используя существующие заказы, где в составе только одна пицца и указана цена заказа.

```
single_item_orders <- orders %>%
  filter(!str_detect(order, ", ")) %>%  # Нет запятой с пробелом - одна
позиция
  distinct(order, order_price)
single_item_orders %>%
  arrange(order_price)
```

```
             order order_price
            <char>       <num>
 1:      Маргарита         479
 2:    Четыре сыра         499
 3: Вегетарианская         510
 4:      Гавайская         520
 5:       Пеперони         530
 6: Неаполитанская         530
 7:    Сицилийская         545
 8:         Дьябло         560
 9:    Мясной микс         579
10:        3 пиццы        1299
```

Таким образом, удалось восстановить цену на отдельные пиццы, и почти все имеют разную цену, только Пеперони и Неаполитанская стоят одинаково (530). Следовательно, восстановить заказы, где в составе есть пицца по такой цене мы не сможем полностью, напишем, что это Пеперони или Неаполитанская.

Восстановим пустые заказы с помощью комбинаторики, используя цены для отдельных пицц, перебирая известные цены, пока комбинация не сойдется.

```
find_combination <- function(target_price, prices,
                             items, max_items = 4) {
  # Создаём список комбинаций для разного числа элементов (от 1 до max_items)
и объединяем все комбинации в один список
  all_combos <-  map(1:max_items, ~combn(prices, .x, simplify = FALSE)) %>%
flatten()

  matched_combos <- keep(all_combos, ~sum(.x) == target_price) %>%
    map(sort) %>%
    unique()
    # Преобразуем каждую комбинацию цен в соответствующие элементы
    matched_items_list <- map(matched_combos, ~{
      matched_prices <- .x
      matched_items <- items[match(matched_prices, prices)]
      paste(matched_items, collapse = ", ")
```

```
    })
    # Объединяем все комбинации через ИЛИ
    return(paste(matched_items_list, collapse = " ИЛИ "))
}

# запускаем только для тех строк, где пропущен состав заказа
orders[is.na(order), order_recovered := map_chr(order_price,
find_combination,
                                    prices = single_item_orders$order_price,
                                    items = single_item_orders$order)] %>%
  .[, order_recovered := coalesce(order, order_recovered)]

# теперь заменяем Пеперони или Неаполитанская везде, где мы восстановили
заказ на Пеперони/Неаполитанская

orders[str_detect(order_recovered, 'Пеперони|Неаполитанская') & is.na(order),
       order_recovered := str_replace(order_recovered,
'Пеперони|Неаполитанская', 'Пеперони/Неаполитанская')]

# проверим, сколько осталось пропущенных значений:
sum(is.na(orders$order_recovered))
```

```
[1] 0
```

```
# запишем это в файл
writexl::write_xlsx(orders, 'orders_recovered.xlsx')
```

Данные восстановлены, почти всё, кроме наличия в составе Пеперони и Неаполитанской удалось восстановить точно. Кроме этого, некоторые заказы допускают несколько комбинаций, они указаны через ИЛИ в поле order_recovered, например в заказе с ценой 1549, с такой ценой могут быть Маргарита, Вегетарианская, Дьябло ИЛИ Четыре сыра, Гавайская, Пеперони/Неаполитанская.

По ссылке можно ознакомиться с восстановленными данными.

Определить злоумышленников

Построим распределение цен по заказам, чтобы понять, есть ли какой-то паттерн в пропущенных значениях в зависимости от цены.

```
orders %>%
  mutate(is_missed = if_else(is.na(order), 'Пропущены', 'Не пропущены')) %>%
  ggplot(aes(order_price))+
  geom_histogram()+
  facet_wrap(~is_missed, nrow = 2)+
  ggtitle('Распределение цен в зависимости от пропусков')+
  theme_bw()
```

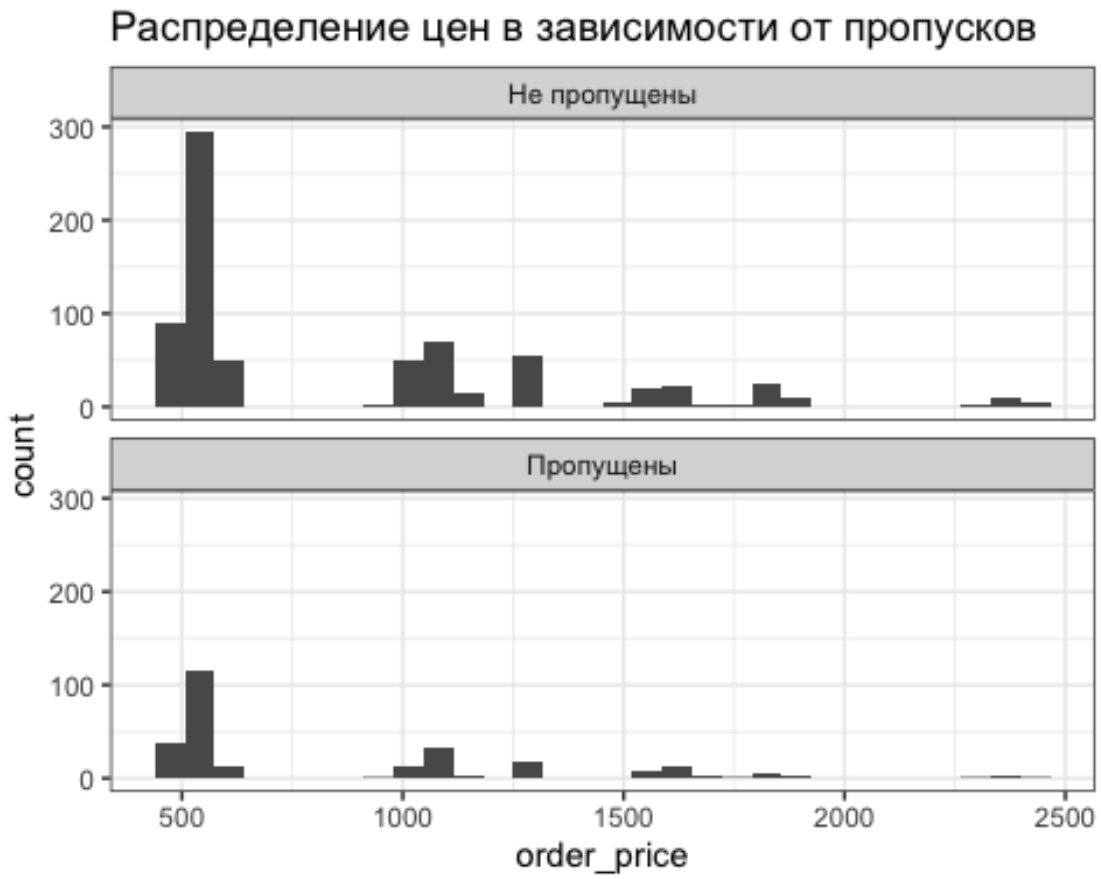

Определенного паттерна не наблюдается, пропущенные заказы имеют схожее распределение по цене с существующими.

Распределение по устройствам тоже не дает определенной информации, встречаются устройства mobile, unknown и web с примерно одинаковой частотой.

```
device %>%
    count(device)

    device     n
    <char> <int>
1:  mobile   359
2: unknown   323
3:     web   318
```

Давайте посмотрим на распределение ip по таблице `device`.

Сначала проанализируем диапазон ip.

```
device %>%
  summarise(min(ip), max(ip))

        min(ip)        max(ip)
1 192.168.1.122 192.168.99.220
```

Диапазон ip в датасета от 192.168.1.122 до 192.168.99.220, что говорит о том, что все ip внутренние, а значит заказы обрабатываются через внутреннюю систему. Другая гипотеза, что для кейса замаскированы реальные ip. Рассмотрим вариант, в котором это будут действительно внутренние ip, через которые проходит заказ.

Найдем топ-10 самых часто встречающихся ip в таблице

```
device %>%
  count(ip) %>%
  arrange(desc(n)) %>%
  head(10)
```

```
                ip     n
             <char> <int>
 1:  192.168.47.168   222
 2:  192.168.27.148   182
 3:   192.168.4.125    75
 4:  192.168.84.205    75
 5:  192.168.96.217    75
 6:  192.168.13.134    24
 7:  192.168.69.190    24
 8: 192.168.100.221    19
 9:  192.168.29.150    19
10:  192.168.77.198    19
```

Самый часто встречающийся ip 192.168.47.168, с 222 вхождения в таблице device.

Давайте соединим таблицы `orders` и `device` по полю user_id и выведем заказы и юзер айди для самого часто встречающегося ip адреса

```
df <- orders %>% full_join(device, by = 'user_id')
df %>%
  filter(ip == '192.168.47.168') %>%
  arrange(order_id) %>%
  select(order_id, order, user_id, ip, device, operator_ip) %>%
  head(10)
```

```
    order_id                                    order user_id             ip
       <num>                                   <char>   <num>         <char>
 1:        1                                3 пиццы  653310 192.168.47.168
 2:        2                                 Дьябло  790532 192.168.47.168
 3:        3 Вегетарианская, Неаполитанская, Дьябло  643164 192.168.47.168
 4:        4                              Гавайская  262399 192.168.47.168
 5:        5                               Пеперони  554538 192.168.47.168
 6:        6 Сицилийская, Гавайская, Неаполитанская  529058 192.168.47.168
 7:        7                           Мясной микс  833483 192.168.47.168
 8:        8                                  <NA>  576038 192.168.47.168
 9:        9                                  <NA>  263237 192.168.47.168
10:       10                                 Дьябло  564737 192.168.47.168
     device     operator_ip
     <char>          <char>
```

```
 1:  mobile 192.168.214.114
 2: unknown 192.168.213.113
 3:  mobile 192.168.207.107
 4:     web 192.168.207.107
 5:     web 192.168.214.114
 6: unknown 192.168.218.118
 7: unknown 192.168.206.106
 8: unknown 192.168.202.102
 9:     web 192.168.203.103
10:     web 192.168.213.113
```

Обращаю внимание, что все order_id с этого ip-адреса идут по порядку, но при этом юзереймы разные и попадают на разные operator_ip.

Самый часто встречающийся user_id с таким ip - это 796365, что тоже может указывать на возможный источник атаки.

```
device %>%
  filter(ip == '192.168.47.168') %>%
  count(user_id) %>%
  arrange(desc(n)) %>%
  head(3)

   user_id     n
     <num> <int>
1:  796365     5
2:  119110     1
3:  119700     1
```

Допущение такое, что все заказы с одного ip - это действительно заказы с одного ip-адреса (а не условность кейса), что делает подобную частоту заказов с одного адреса подозрительной. Это похоже на намеренную перегрузку системы, что могло вызвать сбой.

Проверим следующий часто встречающийся в данных ip адрес: 192.168.27.148

```
df %>%
  filter(ip == '192.168.27.148') %>%
  arrange(order_id) %>%
  select(order_id, order, user_id, ip, device, operator_ip) %>%
  head(10)

    order_id                                order user_id             ip
device
       <num>                               <char>   <num>         <char>
<char>
 1:      223                               Дьябло  235555 192.168.27.148
unknown
 2:      224                                 <NA>  657248 192.168.27.148
mobile
 3:      225                             3 пиццы  176961 192.168.27.148
```

```
mobile
 4:      226                            Гавайская  469335 192.168.27.148
mobile
 5:      227                             Пеперони  400617 192.168.27.148
mobile
 6:      228                           Сицилийская  917234 192.168.27.148
unknown
 7:      229                                  <NA>  828469 192.168.27.148
unknown
 8:      230 Неаполитанская, Дьябло, Мясной микс  404480 192.168.27.148
mobile
 9:      231                                  <NA>  227181 192.168.27.148
unknown
10:      232                              3 пиццы  818565 192.168.27.148
web
        operator_ip
             <char>
 1: 192.168.210.110
 2: 192.168.203.103
 3: 192.168.211.111
 4:  192.168.91.212
 5: 192.168.218.118
 6: 192.168.203.103
 7: 192.168.218.118
 8:  192.168.85.206
 9: 192.168.203.103
10: 192.168.203.103
```

Здесь тоже заказы идут по порядку, что усиливает подозрения, что это не случайность.

Самый часто встречающийся юзер с этого айпи: 853594, 5 заказов.

```
device %>%
  filter(ip == '192.168.27.148') %>%
  count(user_id) %>%
  arrange(desc(n)) %>%
  head(3)

   user_id     n
     <num> <int>
1:  853594     5
2:  118997     1
3:  122358     1
```

Подозреваем, что два ip 192.168.47.168 и 192.168.27.148 устроили атаку, если это внутренний айпи, то стоит отследить, что это за устройство и кто имеет к нему доступ, посмотреть записи с камер наблюдения.

Еще можно посмотреть на совпадающие айпи пользователей и оператор айпи.

```
device[ip %in% operator_ip, ]
```

	ip	device	operator_ip	user_id
	<char>	<char>	<char>	<num>
1:	192.168.91.212	mobile	192.168.207.107	307937
2:	192.168.91.212	web	192.168.215.115	307937
3:	192.168.46.167	mobile	192.168.213.113	363028
4:	192.168.46.167	web	192.168.209.109	363028
5:	192.168.46.167	unknown	192.168.211.111	363028
6:	192.168.85.206	web	192.168.212.112	532741
7:	192.168.85.206	mobile	192.168.203.103	532741
8:	192.168.85.206	web	192.168.207.107	532741

Здесь айпи адреса 192.168.91.212, 192.168.46.167, 192.168.85.206, которые встречаются и в пользовательском айпи, и в айпи оператора. Это тоже подозрительно и указывает на потенциальный взлом. Устройство одновременно клиент и оператор (например, взломанный терминал).

Соответственно, наиболее подозрительные ip это 192.168.47.168 и 192.168.27.148, по критерию наиболее частотных заказов и 192.168.91.212, 192.168.46.167, 192.168.85.206 по критерию одинаковых пользовательских ip и ip оператора. Все похоже на внутреннюю атаку, рекомендация посмотреть также камеры видеонаблюдения и посмотреть логи сотрудников, которые имеют доступ к подозрительным адресам.

Распределение компенсации пострадавшим

Гипотеза, что настоящие пользователи не с вышеуказанными айпи.

У нас есть 90000р, чтобы распределить между настоящими пострадавшими. Думаю, стоит это сделать пропорционально сумме заказов.